

**CLASSIFICATION LOGISTIC REGRESSION, K-NEAREST
NEIGHBOR, NAIVE BAYES, DECISION TREE**

disusun untuk memenuhi
tugas mata kuliah Pemrosesan Mesin B

oleh :

Mila Lestari	(2208107010002)
Zahra Zafira	(2208107010040)
Pryta Rosela	(2208107010046)
Cut Sula Fhatia Rahma	(2208107010048)
Widya Nurul Sukma	(2208107010054)



**JURUSAN INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA**

2025

1. Pendahuluan dan Pemahaman Dataset

Laporan ini menyajikan analisis komprehensif tentang klasifikasi penyakit jantung menggunakan empat algoritma machine learning: Logistic Regression, K-Nearest Neighbors (KNN), Naïve Bayes, dan Decision Tree. Analisis ini memberikan wawasan tentang fitur-fitur penting dan metrik kinerja model yang dapat membantu dalam sistem pendukung keputusan klinis untuk prediksi penyakit jantung. Laporan ini juga menyertakan visualisasi dan interpretasi hasil yang komprehensif untuk membantu pemahaman yang lebih baik tentang model yang diimplementasikan.

1.1 Sumber Dataset

Analisis ini menggunakan dataset "heart.csv" yang berisi berbagai atribut medis dan demografis terkait dengan diagnosis penyakit jantung. Dataset ini mencakup atribut kategorikal dan numerik, dengan target klasifikasi biner yang menunjukkan ada tidaknya penyakit jantung. Berikut Link Dataset:

<https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

1.2 Gambaran Dataset

Dataset terdiri dari fitur-fitur berikut:

- Informasi demografis: Age (Usia), Sex (Jenis Kelamin)
- Pengukuran medis: RestingBP (Tekanan Darah Istirahat), Cholesterol (Kolesterol), FastingBS (Gula Darah Puasa), MaxHR (Detak Jantung Maksimum), Oldpeak (Depresi ST)
- Observasi klinis: ChestPainType (Jenis Nyeri Dada), RestingECG (EKG Istirahat), ExerciseAngina (Angina Akibat Olahraga), ST_Slope (Kemiringan Segmen ST)
- Variabel target: HeartDisease (0 = Tidak, 1 = Ya)

Dataset ini terdiri dari beberapa ratus sampel dengan 11 fitur prediktif. Semua fitur memiliki nilai yang lengkap tanpa adanya nilai yang hilang, sehingga memudahkan dalam proses analisis dan pemodelan.

1.3 Statistik Deskriptif Dataset

Berikut adalah statistik deskriptif dari dataset:

Statistik Deskriptif:					
	Age	RestingBP	Cholesterol	FastingBS	MaxHR
count	918.000000	918.000000	918.000000	918.000000	918.000000
mean	53.510893	132.396514	198.799564	0.233115	136.809368
std	9.432617	18.514154	109.384145	0.423046	25.460334
min	28.000000	0.000000	0.000000	0.000000	60.000000
25%	47.000000	120.000000	173.250000	0.000000	120.000000
50%	54.000000	130.000000	223.000000	0.000000	138.000000
75%	60.000000	140.000000	267.000000	0.000000	156.000000
max	77.000000	200.000000	603.000000	1.000000	202.000000

	Oldpeak	HeartDisease
count	918.000000	918.000000
mean	0.887364	0.553377
std	1.066570	0.497414
min	-2.600000	0.000000
25%	0.000000	0.000000
50%	0.600000	1.000000
75%	1.500000	1.000000
max	6.200000	1.000000

Gambar 1.1 Deskriptif dataset

Dari statistik deskriptif, dapat disimpulkan bahwa:

- Usia rata-rata subjek adalah sekitar 53 tahun, dengan rentang dari 28 hingga 77 tahun
- Nilai rata-rata kolesterol adalah sekitar 198 mg/dL
- Detak jantung maksimum rata-rata adalah sekitar 136 bpm
- Dataset ini tidak memiliki nilai yang hilang, sehingga memudahkan proses analisis

1.4 Distribusi Dataset

Distribusi kelas target (HeartDisease) menunjukkan dataset yang relatif seimbang:



Gambar 1.2 Distribusi kelas target

Distribusi yang seimbang ini memungkinkan pelatihan model yang efektif tanpa masalah ketidakseimbangan kelas yang signifikan. Sekitar 55% sampel diklasifikasikan sebagai memiliki penyakit jantung (nilai 1) dan 45% diklasifikasikan sebagai tidak memiliki penyakit jantung (nilai 0).

2. Eksplorasi Data dan Pra-pemrosesan

2.1 Analisis Nilai Hilang

```
Missing Values:
Age           0
Sex           0
ChestPainType 0
RestingBP     0
Cholesterol   0
FastingBS     0
RestingECG    0
MaxHR         0
ExerciseAngina 0
Oldpeak       0
ST_Slope      0
HeartDisease  0
dtype: int64
```

Gambar 2.1 Missing values


Analisis dataset menunjukkan tidak ada nilai yang hilang, yang menyederhanakan langkah pra-pemrosesan karena tidak diperlukan teknik imputasi.

2.2 Analisis Korelasi

Matriks korelasi menunjukkan hubungan antara berbagai fitur:



Gambar 2.2 Matriks korelasi



Gambar 2.3 korelasi Fitur Numerik dengan Target (HeartDisease)

Dari matriks korelasi, dapat diobservasi bahwa:

- **Oldpeak** dan **Age** adalah dua fitur yang **paling kuat** berkorelasi dengan **HeartDisease**.
- **FastingBS** dan **RestingBP** juga **agak berkorelasi** dengan HeartDisease, tapi tidak sekuat MaxHR dan Oldpeak.
- Fitur lain seperti **Cholesterol** dan **MaxHR** **berkorelasi Negatif** terhadap HeartDisease di dataset ini.

2.3 Langkah-langkah Pra-pemrosesan

Berikut langkah-langkah pra-pemrosesan yang diimplementasikan:

1. **Label Encoding untuk fitur kategori:** Fitur-fitur seperti Sex, ChestPainType, RestingECG, ExerciseAngina, dan ST_Slope diubah menjadi bentuk numerik menggunakan LabelEncoder. Langkah ini penting karena algoritma machine learning bekerja dengan data numerik.

```
# Daftar fitur kategorikal
categorical_features = ['Sex', 'ChestPainType', 'RestingECG', 'ExerciseAngina', 'ST_Slope']

# Lakukan label encoding pada setiap fitur kategorikal
le = LabelEncoder()
for feature in categorical_features:
    X[feature] = le.fit_transform(X[feature])
```

Gambar 2.4 Label Encoding untuk fitur kategori

2. **Standardisasi fitur numerik:** Semua fitur numerik distandarisasi menggunakan StandardScaler untuk menormalkan skala. Langkah ini memastikan bahwa semua fitur memiliki skala yang sama, yang penting untuk algoritma seperti Logistic Regression dan KNN yang sensitif terhadap skala.

```
# Standarisasi fitur numerik
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Gambar 2.5 Standardisasi fitur numerik

3. **Pembagian data training dan testing:** Dataset dibagi menjadi 80% data training dan 20% data testing dengan random_state=42 untuk memastikan hasil yang dapat direproduksi.

```
# Split data
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, random_state=42)
```

Gambar 2.6 Pembagian data training dan testing

3. Implementasi Model

3.1 Logistic Regression

Model Logistic Regression diimplementasikan dengan parameter max_iter=1000 untuk memastikan konvergensi dan random_state=42 untuk reproduksibilitas.

```
# Model 1: Logistic Regression
lr_model = LogisticRegression(max_iter=1000, random_state=42)
lr_model.fit(X_train, y_train)
y_pred_lr = lr_model.predict(X_test)
y_prob_lr = lr_model.predict_proba(X_test)[:, 1] # untuk kurva ROC
```

Gambar 3.1 Model Logistic Regression

Logistic Regression merupakan algoritma klasifikasi yang memodelkan probabilitas kelas target menggunakan fungsi logistik. Model ini cocok untuk kasus klasifikasi biner seperti prediksi penyakit jantung, dengan keunggulan interpretabilitas yang baik.

3.2 K-Nearest Neighbors (KNN)

3.2.1 Pencarian Nilai K Optimal

Untuk menemukan nilai K optimal, dilakukan cross-validation dengan K dari 1 hingga 30:


```
# Mencari K optimal
k_range = range(1, 31)
k_scores = []
for k in k_range:
    knn = KNeighborsClassifier(n_neighbors=k)
    scores = cross_val_score(knn, X_train, y_train, cv=5, scoring='accuracy')
    k_scores.append(scores.mean())

# Visualisasi pencarian K terbaik
plt.figure(figsize=(10, 6))
plt.plot(k_range, k_scores)
plt.xlabel('Nilai K')
plt.ylabel('Cross-Validated Accuracy')
plt.title('Nilai Akurasi vs. Nilai K')
plt.grid(True)
plt.show()

# Pilih K optimal
optimal_k = k_scores.index(max(k_scores)) + 1
print(f"K optimal: {optimal_k}")
```

Gambar 3.2 Pencarian Nilai K Optimal KNN

Hasil visualisasi menunjukkan performa model dengan berbagai nilai K:



Gambar 3.3 Visualisasi nilai akurasi dan nilai K

Dari grafik tersebut, nilai K=13 memberikan akurasi tertinggi dalam cross-validation.

3.2.2 Implementasi KNN dengan K Optimal

Setelah menemukan nilai K optimal, model KNN diimplementasikan:

```
# Terapkan model KNN dengan K optimal
knn_model = KNeighborsClassifier(n_neighbors=optimal_k)
knn_model.fit(X_train, y_train)
y_pred_knn = knn_model.predict(X_test)
y_prob_knn = knn_model.predict_proba(X_test)[:, 1] # untuk kurva ROC
```

Gambar 3.4 Implementasi KNN dengan K Optimal

KNN adalah algoritma yang mengklasifikasikan sampel baru berdasarkan "suara terbanyak" dari K tetangga terdekatnya. Dengan nilai K=13, model ini mencapai keseimbangan optimal antara bias dan variansi.

3.3 Naïve Bayes

Model Naïve Bayes diimplementasikan menggunakan GaussianNB, yang mengasumsikan fitur mengikuti distribusi normal:

```
# Model 3: Naive Bayes
nb_model = GaussianNB()
nb_model.fit(X_train, y_train)
y_pred_nb = nb_model.predict(X_test)
y_prob_nb = nb_model.predict_proba(X_test)[:, 1] # untuk kurva ROC
```

Gambar 3.5 Model Naive Bayes

Algoritma Naïve Bayes menerapkan teorema Bayes dengan asumsi "naif" bahwa setiap fitur bersifat independen. Meskipun asumsi ini mungkin tidak selalu terpenuhi dalam data medis, model ini tetap efektif dan komputasional efisien.

3.4 Decision Tree

Model Decision Tree diimplementasikan dengan parameter default dan random_state=42:

```
# Model 4: Decision Tree
dt_model = DecisionTreeClassifier(random_state=42)
dt_model.fit(X_train, y_train)
y_pred_dt = dt_model.predict(X_test)
y_prob_dt = dt_model.predict_proba(X_test)[:, 1] # untuk kurva ROC
```

Gambar 3.6 Model Decision Tree

Decision Tree membuat model prediktif berdasarkan serangkaian keputusan biner. Model ini menawarkan interpretabilitas yang baik tetapi rentan terhadap overfitting, terutama pada dataset kecil.


4. Evaluasi Model

4.1 Perbandingan Metrik Kinerja

Berikut adalah perbandingan metrik kinerja untuk keempat model:


Model	Accuracy	Precision	Recall	F1 Score	Log loss
Logistic Regression	0.8478	0,8546	0,8478	0,8487	0,4083
KNN	0.8315	0,8395	0,8315	0,8325	0,6864
Naive Bayes	0.8423	0,8448	0,8423	0,8429	0,5682
Decision Tree	0.7826	0,7945	0,7826	0,7840	7,8355

Visualisasi perbandingan metrik:

A screenshot of a terminal window with a dark background and light-colored text. It displays a table of performance metrics for four machine learning models: Logistic Regression, K-Nearest Neighbor, Naive Bayes, and Decision Tree. The metrics shown are accuracy, precision, recall, f1, and log_loss. The values are formatted with leading zeros and commas as decimal separators.

Perbandingan Kinerja Model:					
	accuracy	precision	recall	f1	log_loss
Logistic Regression	0.847826	0.854653	0.847826	0.848736	0.408306
K-Nearest Neighbor	0.831522	0.839561	0.831522	0.832573	0.686466
Naive Bayes	0.842391	0.844828	0.842391	0.842984	0.568207
Decision Tree	0.782609	0.794548	0.782609	0.784058	7.835577

Gambar 4.1 Metrik perbandingan model




Gambar 4.2 Visualisasi perbandingan model

Dari tabel dan visualisasi di atas, dapat disimpulkan bahwa:


- **Logistic Regression** menunjukkan kinerja terbaik secara keseluruhan dengan **akurasi 84,78%**, precision, recall, dan F1 score yang juga tinggi dan seimbang.
- **Naïve Bayes** berada di urutan kedua dengan **akurasi 84,24%**, hanya sedikit di bawah Logistic Regression, menjadikannya alternatif yang kompetitif.
- **K-Nearest Neighbor (K=13)** menunjukkan kinerja yang baik dengan **akurasi 83,15%**, meskipun sedikit lebih rendah dibanding dua model sebelumnya.
- **Decision Tree** memiliki performa terendah dengan **akurasi 78,26%**, yang bisa mengindikasikan kemungkinan **overfitting** atau kebutuhan akan tuning parameter lebih lanjut.

4.2 Kurva ROC dan Skor AUC

Kurva ROC (Receiver Operating Characteristic) dan skor AUC (Area Under Curve) untuk setiap model:



Gambar 4.3 ROC kurva Logistic Regression dan KNN




Gambar 4.4 ROC kurva Naive Bayes dan Decision Tree


Semua model menghasilkan kurva ROC dengan skor AUC di atas 0,7, yang menunjukkan kemampuan diskriminatif yang baik. Model K-Nearest Neighbor menunjukkan AUC tertinggi, diikuti oleh model Naïve Bayes. Skor AUC yang tinggi menunjukkan bahwa model tersebut memiliki kemampuan yang baik untuk membedakan antara kelas positif dan negatif.

4.3 Confusion Matrix

Confusion Matrix untuk setiap model:



Gambar 4.5 Confusion Matrix Logistic Regression dan KNN



Gambar 4.6 Confusion Matrix Naive Bayes dan Decision Tree

Dari confusion matrix untuk setiap model, dapat diobservasi bahwa:


- **Logistic Regression:** False positive terendah dan kesalahan keseluruhan rendah, tetapi false negative sedikit lebih tinggi dari Naïve Bayes.
- **Decision Tree:** Error tertinggi dengan false positive dan false negative paling banyak.
- **KNN dan Naïve Bayes:** Pola kesalahan mirip, namun Naïve Bayes lebih baik dalam mengurangi false negative

Confusion matrix membantu kita memahami jenis kesalahan yang dilakukan oleh setiap model. Dalam konteks medis, penting untuk mempertimbangkan biaya dari false negative (tidak mendeteksi penyakit jantung ketika sebenarnya ada) dan false positive (mendeteksi penyakit jantung ketika sebenarnya tidak ada).

5. Analisis Fitur Penting

5.1 Feature Importance pada Decision Tree

Decision Tree mengidentifikasi fitur-fitur prediktif utama berikut:



Gambar 5.1 Visualisasi fitur penting


Dari analisis feature importance pada model Decision Tree, dapat disimpulkan bahwa:

- **ST_Slope** merupakan fitur paling penting dalam memprediksi penyakit jantung.
- **MaxHR**, **Cholesterol**, dan **Age** juga berkontribusi signifikan terhadap prediksi
- Fitur lain seperti **ChestPainType**, **ExerciseAngina**, **RestingECG** dan lainnya, memiliki kontribusi lebih kecil dibandingkan fitur-fitur utama tersebut.

Fitur-fitur ini memainkan peran penting dalam menentukan ada tidaknya penyakit jantung menurut model.

5.2 Koefisien Logistic Regression

Koefisien model Logistic Regression menunjukkan:



Gambar 5.2 Visualisasi koefisien Logistic Regression

Dari analisis koefisien Logistic Regression:

- **ExerciseAngina, Sex, Oldpeak, FastingBS, Age dan RestingBP** berasosiasi **positif** dengan peningkatan risiko penyakit jantung.
- **ST_Slope, ChestPainType, Cholesterol, MaxHR dan RestingECG** berasosiasi **negatif**, artinya peningkatan nilai fitur ini justru menurunkan risiko.

Koefisien positif menunjukkan bahwa peningkatan nilai fitur tersebut meningkatkan kemungkinan penyakit jantung, sedangkan koefisien negatif menunjukkan bahwa peningkatan nilai fitur tersebut menurunkan kemungkinan penyakit jantung.

6. Kesimpulan dan Rekomendasi

6.1 Ringkasan Kinerja Model

1. **Logistic Regression** mencapai akurasi tertinggi (84,78%) dan menunjukkan kinerja terbaik secara keseluruhan untuk semua metrik.
2. **Naïve Bayes** memberikan kinerja kedua terbaik dengan akurasi 84,24%.
3. **KNN** dengan K optimal=13 menunjukkan kinerja yang baik dengan akurasi 83,15%.
4. **Decision Tree** memiliki akurasi terendah yaitu 78,26%, menunjukkan kemungkinan masalah overfitting.

Dari hasil analisis ini, Logistic Regression adalah model yang paling direkomendasikan untuk implementasi karena memiliki keseimbangan terbaik antara akurasi dan interpretabilitas.

6.2 Implikasi Klinis

Kekuatan prediktif dari fitur-fitur seperti ST_Slope, MaxHR, dan Cholesterol sesuai dengan literatur medis tentang faktor risiko penyakit jantung. Temuan ini dapat membantu penyedia layanan kesehatan untuk fokus pada indikator utama selama penilaian pasien.

Implikasi klinis dari model ini termasuk:

- Kemampuan untuk melakukan penilaian risiko awal berdasarkan parameter klinis yang mudah diukur
- Potensi untuk mengidentifikasi pasien yang mungkin memerlukan pemeriksaan lebih lanjut
- Alat pendukung keputusan klinis yang dapat membantu dokter dalam mendiagnosis penyakit jantung

6.3 Keterbatasan Model

Meskipun model-model ini menunjukkan kinerja yang baik, ada beberapa keterbatasan yang perlu diperhatikan:

- Dataset yang digunakan memiliki ukuran sedang; model mungkin mendapatkan manfaat dari data yang lebih banyak

- Beberapa fitur kategorikal diubah menjadi bentuk numerik menggunakan label encoding, yang mungkin tidak selalu mewakili hubungan yang tepat

7. Referensi

- Library Python yang digunakan: NumPy, Pandas, Matplotlib, Seaborn, Scikit-learn
- Sumber dataset: [Heart Failure Prediction Dataset | Kaggle](#)
- Teknik machine learning: Logistic Regression, K-Nearest Neighbors, Naïve Bayes, Decision Tree
- Metrik evaluasi: Accuracy, Precision, Recall, F1-Score, ROC Curve, AUC Score

8. Lampiran

8.1 Kode Lengkap

Kode Python lengkap untuk reproduksi analisis terdapat dalam file Jupyter Notebook dengan link sebagai berikut: [🔗 Tugas 3 Kelompok.ipynb](#) .

8.2 Video Presentasi

Link youtube presentasi adalah sebagai berikut: [Tugas_03_Classification](#)

8.3 Link Github

Link Repositori adalah sebagai berikut: [Tugas03_Classification](#)